

Estudio de la distribución espacial de depósitos Ígneo/Metamórficos en Antioquia-Caldas-Risaralda, predicción a partir de patrones espaciales mediante modelos de regresión.

Santiago Cruz-Alvarado

Facultad de Minas, Universidad Nacional de Colombia, Medellín-Antioquía, Colombia.

Email: scruza@unal.edu.co

Resumen

Este estudio analiza la distribución espacial de depósitos ígneo-metamórficos en los departamentos de Antioquia, Caldas y Risaralda, utilizando modelos estadísticos y espaciales para predecir la probabilidad de ocurrencia de mineralizaciones. Se integran técnicas de regresión logística con modelos espaciales como SLX (Spatial Lag of X) y SAR-Logit, incorporando covariables geoquímicas y geofísicas derivadas de datos de sedimentos activos e interpolación espacial mediante IDW. La base de datos incluye eventos positivos y pseudoausencias generadas de forma aleatoria para calibrar los modelos. Los resultados muestran que el modelo SLX supera a los modelos base y SAR-Logit en métricas como AUC-ROC (0.87), F1-score (0.80) y pseudo- R^2 de McFadden (0.34), reduciendo además la autocorrelación espacial de los residuos (Moran's $I = 0.33$). El análisis de coeficientes revela que variables como EdadMa, Moho_Z y Bario son los principales predictores de la presencia de mineralizaciones. Estos hallazgos demuestran la importancia de incorporar componentes espaciales en la modelación geoestadística, permitiendo una interpretación más robusta y mapas de susceptibilidad con mayor precisión para apoyar procesos de exploración mineral en la región.

Palabras clave: depósitos ígneo-metamórficos; autocorrelación espacial; regresión logística; SLX; SAR-Logit.

Study of the spatial distribution of igneous/metamorphic deposits in Colombia, prediction based on spatial patterns.

Abstract

This study examines the spatial distribution of igneous-metamorphic deposits in the departments of Antioquia, Caldas, and Risaralda, using statistical and spatial models to predict the probability of mineralization occurrence. Logistic regression is combined with spatial models such as SLX (Spatial Lag of X) and SAR-Logit, integrating geochemical and geophysical covariates derived from active sediment data and spatial interpolation through IDW. The database includes positive events and randomly generated pseudo-absences for model calibration. Results indicate that the SLX model outperforms both the base and SAR-Logit models in metrics such as AUC-ROC (0.87), F1-score (0.80), and McFadden's pseudo- R^2 (0.34), while also reducing spatial autocorrelation of residuals (Moran's $I = 0.33$). Coefficient analysis highlights variables like EdadMa, Moho_Z, and Barium as key predictors of mineralization presence. These findings emphasize the importance of incorporating spatial components into geostatistical modeling, enabling more robust interpretation and more accurate susceptibility maps to support mineral exploration in the region.

Keywords: igneous-metamorphic deposits; spatial autocorrelation; logistic regression; SLX; SAR-Logit.

I. Introducción

La modelación espacial de fenómenos geológicos permite comprender y predecir patrones que no son independientes en el espacio, sino que presentan una dependencia asociada a su localización geográfica. En este trabajo se pretende abordar el análisis de eventos distribuidos en la zona con más ubicaciones de manifestaciones minerales asociadas a procesos ígneo/metamórficos, encontrándose esta delimitada por los departamentos de Antioquia, Caldas y Risaralda, mediante técnicas de regresión logística complementadas con modelos espaciales como SLX (Spatial Lag of X) y SARlogit (Spatial Autoregressive Logistic Model). Estas metodologías permiten incorporar explícitamente la autocorrelación espacial en los datos, logrando predicciones más precisas y una interpretación más robusta de los factores que influyen en la presencia o ausencia de eventos.

DISTRIBUCIÓN GEOGRÁFICA DE LAS MINERALIZACIONES Y DENSIDAD DE KERNEL




Figura 1. Mapas distribución y densidad de las mineralizaciones.

La base de datos utilizada es generada por (Servicio Geológico Colombiano, 2020), combina registros puntuales de eventos (positivos), de mineralizaciones en todo el país (Figura 1). A esta base de datos se le filtraron aquellas mineralizaciones asociadas de eventos

ígneo/metamórficos y se delimitó el estudio a los departamentos del país que agrupan la mayor cantidad de mineralizaciones en el país, siendo estos Antioquia, Caldas y Risaralda (Figura 2). A esta base de datos se le añadieron un conjunto de pseudoausencias (negativos) generadas mediante muestreo aleatorio dentro del área de estudio. Posterior a ello, a los eventos positivos y a los evento negativos se les imputan valores de las variables predictoras a través de técnicas de interpolación espacial como IDW (Inverse Distance Weighting). Las covariables consideradas incluyen variables geoquímicas y geofísicas, las cuales se analizan en relación con la probabilidad de ocurrencia de los eventos.




Figura 2. Mapas distribución y densidad de las mineralizaciones para el área de estudio.

Adicionalmente, se implementan medidas de autocorrelación espacial, como el índice de Moran global y local, para diagnosticar la presencia de patrones espaciales significativos en los residuos de los modelos. Con estos análisis se busca no solo mejorar la capacidad predictiva, sino también comprender la influencia espacial en los procesos modelados. Los resultados se presentan a través de mapas de predicción (probabilidad de ocurrencia), análisis de importancia de variables (coeficientes y p-valores), y métricas de desempeño

como AUCROC, F1score y pseudoR². Este trabajo se orienta, por tanto, a la integración de técnicas de análisis espacial y aprendizaje estadístico para la modelación probabilística de eventos georreferenciados, contribuyendo a una mejor comprensión de los patrones espaciales y a la toma de decisiones en la región estudiada.

2. Marco teórico

2.1 Geología de exploración.

Los métodos geoquímicos permiten identificar “huellas” químicas sutiles que dejan los depósitos minerales en los materiales superficiales. En regiones montañosas como los Andes, los geólogos realizan muestreos sistemáticos de diferentes medios (sedimentos de corrientes, suelos y rocas aflorantes) para detectar anomalías geoquímicas de elementos traza asociados a mineralización. Estas anomalías, una vez identificadas, sirven como guías hacia posibles yacimientos ocultos. Dentro de estos métodos, el trabajo presente hizo uso de datos obtenido a partir de sedimentos activos de corriente. Las arenas y limos de quebradas en cuencas de drenaje actúan como vectores geoquímicos que concentran los elementos metálicos erosionados de las rocas fuente aguas arriba. El análisis de sedimentos activos es a menudo la primera etapa de exploración regional, pues una sola muestra de corriente integra la señal geoquímica de una amplia área de captación.

En la exploración moderna, los sedimentos activos se analizan mediante técnicas multielemento (ICPMS, espectrometría de fluorescencia de rayos X, etc.) buscando asociaciones anómalas de elementos patrocinatorios (pathfinders) característicos de ciertos depósitos. La firma geoquímica de un tipo de depósito se refleja en combinaciones diagnósticas de elementos: por ejemplo, en prospección de pórfidos cupríferos se monitorean habitualmente Cu, Mo, Pb, Zn, Ag, Mn, entre otros (Leonardo Cajicá-Acosta & Luís Hernán Sánchez-Arred, 2024).

La geocronología absoluta es una herramienta indispensable para relacionar los depósitos minerales con la evolución tectónica regional. Mediante técnicas de datación isotópica, es posible determinar la edad precisa de cristales y minerales formados durante los eventos magmáticos e hidrotermales asociados a la mineralización. Los métodos más empleados en metalogénesis incluyen: UPb (UranioPlomo) en minerales como zircon, titanita, apatito o rutilo; ArAr (ArgónArgón, una derivación del método KAr) en minerales potásicos como biotita, muscovita o sericita; y ReOs (RenioOsmio) en sulfuros, especialmente molibdenita (MoS_2), pero también calcopirita, pirita o minerales de CoNi arsenicales en ciertos casos.

Los métodos geofísicos proporcionan una ventana al subsuelo, revelando la arquitectura estructural y las variaciones físicoquímicas de las rocas a distintas profundidades. En la exploración de yacimientos metálicos, los geofísicos buscan anomalías de campo potencial o de propiedades físicas causadas por cuerpos geológicos inusuales (intrusivos, zonas mineralizadas, estructuras favorables). Cada método geofísico mide un parámetro diferente (densidad, susceptibilidad magnética, velocidad sísmica, conductividad eléctrica, etc.) y por tanto aporta información complementaria.

Las grandes provincias metalogénicas no solo dependen de procesos locales de roca huésped y fluidos, sino que están fuertemente condicionadas por la configuración litosférica y la evolución tectónica a escala regional. En el caso de los Andes, la corteza continental engrosada y otros procesos profundos (como la subducción a baja inclinación, las anomalías térmicas del manto y la delaminación litosférica) juegan un papel crítico en la génesis y enriquecimiento de depósitos minerales. Numerosos estudios han encontrado correlaciones espaciales y temporales entre el espesor de la corteza andina, los cambios en la dinámica de placas y la ubicación/edad de yacimientos metalíferos

2.2 Análisis geoespacial

- Regresión Logística

La regresión logística es un modelo estadístico perteneciente a la familia de los modelos lineales generalizados, utilizado para relacionar un conjunto de variables explicativas (continuas o categóricas) con una variable dependiente binaria (generalmente codificada como 1/0 para indicar presencia/ausencia de un evento). A diferencia de la regresión lineal, la regresión logística aplica la función logística para asegurar que las predicciones estén entre 0 y 1, interpretables como probabilidades.

$$P(Y = 1|\mathbf{x}) = \frac{1}{1 + \exp[-(B_0 + B_1x_1 + \dots + B_kx_k)]},$$

donde B_0 es el intercepto y $B_1, \dots, B_k$, son coeficientes que se estiman por máxima verosimilitud. Estos coeficientes se interpretan en términos del cambio en el logit (logodds) de la probabilidad de evento por unidad de cambio en la variable explicativa correspondiente: por ejemplo, B_j representa el cambio esperado en el logodds de $Y=1$ al aumentar en una unidad X_j , manteniendo las demás variables constantes. Un coeficiente positivo indica que un aumento en la variable está asociado a una mayor probabilidad del evento ($\text{odds} > 1$), mientras que un coeficiente negativo indica lo contrario ($\text{odds} < 1$).

En el contexto espacial, la regresión logística se emplea para modelar la probabilidad de ocurrencia de un fenómeno geográfico binario en función de factores explicativos espaciales. Esto es útil, por ejemplo, para generar mapas de riesgo o susceptibilidad de ciertos eventos (deslizamientos de tierra, inundaciones, cambios de uso de suelo, presencia/ausencia de una especie, incidencia de enfermedad, etc.), a partir de variables ambientales o socioeconómicas. Sin embargo, la regresión logística estándar asume independencia entre las observaciones; en datos espaciales puede existir autocorrelación espacial (los sucesos en ubicaciones

cercanas tienden a parecerse), lo que viola dicha suposición. Por ello, a menudo se complementa con técnicas espaciales (por ejemplo, incorporando efectos espaciales en modelos SARLogit, o usando muestreos que mitiguen la autocorrelación).

- Modelo SLX (Spatial Lag of X)

El modelo SLX (por Spatial Lag of X) es un modelo de regresión espacial que incorpora rezagos espaciales de las variables explicativas, pero no incluye un término de dependencia espacial en la variable dependiente. En su forma más simple, el modelo SLX puede expresarse como:

$$y_i = \beta_0 + \sum_{j=1}^k \beta_j X_{ij} + \sum_{j=1}^k \gamma_j (\mathbf{W} X_j)_i + u_i,$$

En términos más sencillos, el modelo SLX amplía una regresión tradicional agregando variables que representan efectos de spillover espacial de las X: captura cómo los valores de los predictores en vecindarios adyacentes afectan la variable respuesta en i . Por ejemplo, si y_i es el precio de una vivienda, un modelo SLX podría incluir no solo las características propias de la vivienda i (tamaño, calidad, etc.) sino también el promedio de ciertas características de las viviendas vecinas (e.g. nivel socioeconómico medio en las manzanas circundantes) para captar externalidades de entorno.

En resumen, el SLX busca mejorar la explicación de y incorporando información del entorno espacial inmediato, sin forzar que la propia y tenga un efecto retroactivo entre regiones.

- Modelo SARLogit (Spatial Autoregressive Logistic Model)

El modelo SARLogit combina la estructura autorregresiva espacial con una función de enlace logística para manejar variables dependientes binarias. Es esencialmente un modelo logístico

que incluye un rezago espacial de la variable dependiente como predictor. En forma simplificada, el modelo puede expresarse como:

$$\text{logit}[P(Y_i = 1)] = \alpha + \rho \sum_j w_{ij} Y_j + \sum_m \beta_m X_{im},$$

La estimación de modelos SARLogit no es trivial, ya que la presencia del término autorregresivo espacial rompe la independencia condicional habitual en un logit.

3. Metodología

La metodología implementada en este estudio sigue un flujo de trabajo sistemático para integrar análisis exploratorio, procesamiento espacial, modelado estadístico y visualización de resultados. A continuación, se describen las etapas clave:

3.1. Análisis exploratorio de datos espaciales (EDA): Se realizó un análisis exploratorio para comprender la estructura de los datos, revisar la distribución espacial de los eventos positivos y las variables explicativas, así como detectar posibles valores atípicos o datos faltantes. Este análisis incluyó la elaboración de histogramas, diagramas de dispersión, mapas temáticos y cálculos de autocorrelación espacial (Índice de Moran) para evaluar la presencia de patrones espaciales significativos (Figura 3).

3.2. Organización y depuración de la base de datos: Los datos originales de eventos (positivos) se organizaron en un formato tabular unificado, asegurando la correcta proyección espacial (CRS) y estandarización de los nombres de variables. Se excluyeron variables irrelevantes y se normalizaron aquellas con diferentes escalas para su posterior uso en modelos estadísticos. Se filtraron eventos y covariables para el área de estudio debido a ser una zona con gran cantidad de muestro de las covariables y poseer la mayor cantidad de eventos en el país (Figura 4).




Figura 3. Natural Breaks para número de depósitos por municipios.




Figura 4. Aglomeración estadística de eventos positivos.

3.3. Interpolación de variables (IDW): Para variables geoquímicas y geofísicas medidas solo en ciertos puntos, se aplicó la técnica de Inverse Distance Weighting (IDW) con el fin de estimar sus valores en todo el espacio de estudio. Esta técnica asume que puntos cercanos tienen valores similares, calculando un promedio ponderado inverso a la distancia. Se seleccionaron los parámetros de potencia y número de vecinos más adecuados mediante validación cruzada, buscando minimizar el error de interpolación. Las variables interpoladas fueron:

- Profundidad de Moho (Poveda et al, 2018): para determinar la profundidad de la corteza (Figura 5).




Figura 5. Interpolación de Z de Moho para el área de Colombia.

- Catálogo de dataciones radiométricas de Colombia (Gómez Tapias, J. et al 2015): para añadir una variable de caracterización litológica (Figura 6).




Figura 6: Interpolación de edades para puntos con dataciones radiométrica en el área de estudio.

- Mapa geoquímico de Colombia Servicio Geológico Colombiano (SGC). (2022): haciendo uso del muestro de los elementos guías (Pathfinders), tales como Antimonio, Azufre, Bario, Bismuto, Cromo, Mercurio y Plata (Figura 8).




Figura 8: Interpolación de los datos geoquímicos a partir de muestras de Sedimentos

Activos para los elementos previamente descritos.

3.4. Generación de pseudoausencias: Dado que el conjunto de datos originales solo contiene eventos positivos (ocurrencia del fenómeno), se generaron pseudoausencias (puntos negativos) de manera aleatoria dentro del polígono de estudio, asegurando que estos puntos estén espacialmente distribuidos y que no coincidan con eventos positivos (Figura 8). A cada pseudoausencia se le asignaron valores de variables explicativas mediante interpolación IDW.




Figura 8. Eventos positivos (Azul) vs pseudo ausencias aleatorias (Rojo).

3.5. Construcción del DataFrame unificado: Se consolidó un DataFrame con todas las observaciones (eventos positivos y pseudoausencias), incluyendo para cada punto las coordenadas proyectadas y los valores de cada variable predictora. Este conjunto de datos se utilizó como entrada para los modelos logísticos y espaciales (SLX, SARLogit).

3.6. Creación de modelos estadísticos: Se construyeron varios modelos para estimar la probabilidad de ocurrencia del fenómeno:

- Regresión Logística (Logit): Modelo base, sin términos espaciales.
- Modelo SLX: Incluyendo rezagos espaciales de las covariables.
- Modelo SARLogit: Con término autorregresivo en la variable dependiente.

Cada modelo fue evaluado mediante métricas como AUC-ROC, precisión, recall y F1-score. Además, se analizaron los residuos y se calcularon indicadores como el índice de Moran para verificar la autocorrelación espacial remanente.

4. Resultados obtenidos

En una primera instancia se normalizan los datos para genera una matriz de correlación entre las variables y definir patrones y tener unos modelos de regresión más acertados (Figura 9).




Figura 9. Mapa de calor de correlación para las variables previamente interpoladas.

El análisis de correlación entre las variables normalizadas (Figura 9) revela patrones significativos en la relación entre los elementos geoquímicos y las variables geológicas del modelo. Destaca la fuerte correlación positiva entre Azufre y Antimonio (0.77), lo que sugiere un posible comportamiento conjunto o una asociación geoquímica común en los procesos de mineralización. De igual forma, se observa una correlación moderada entre Bismuto y Azufre (0.57), lo que refuerza la hipótesis de que ciertos metales traza están influenciados por los mismos ambientes de formación o procesos hidrotermales. Por otro lado, variables geológicas como Edad Ma y Moho presentan correlaciones bajas con los elementos metálicos (máximo de 0.37), lo que indica que sus variaciones no están directamente relacionadas con la concentración de metales analizados. En general, el mapa de calor muestra que las correlaciones negativas son débiles, siendo la más notable la observada entre Moho y Mercurio (-0.29). Estos resultados reflejan que la mayoría de los elementos estudiados tienen comportamientos relativamente independientes, con algunas asociaciones clave que podrían tener relevancia en la interpretación de los procesos de mineralización en la región analizada.

Posteriormente de generar la normalización y análisis de datos se hace uso de la regresión logística para los eventos positivos y pseudo ausencias.

Métricas Regresión Logística Valor	
AUC-ROC	0.810
Precisión	0.730
Recall (Sensibilidad)	0.771
F1-score	0.750
Pseudo-R ² (McFadden)	0.238
Accuracy	0.74

Tabla 1. Resumen métricas regresión logísticas

El modelo de regresión logística (Tabla 1) presenta un desempeño equilibrado con un AUC-ROC de 0.81, lo que indica una buena capacidad para diferenciar entre eventos positivos y negativos. La exactitud global alcanza el 74 %, mientras que la precisión es de 0.73, lo que sugiere que aproximadamente el 27 % de las predicciones positivas son falsos positivos. El recall de 0.77 señala que el modelo identifica correctamente el 77 % de los casos positivos reales, y el F1-score de 0.75 confirma un equilibrio adecuado entre precisión y sensibilidad. Además, el pseudo- R^2 de McFadden (0.238) se sitúa en un rango considerado moderado-bueno para este tipo de modelos, lo que sugiere que las variables explicativas capturan una proporción relevante de la variabilidad de la respuesta. En conjunto, los resultados reflejan que el modelo puede utilizarse como una línea base confiable, aunque podría mejorarse incorporando componentes espaciales o ajustando el umbral de decisión para optimizar el balance entre falsos positivos y negativos.




Figura 10. Graficas de desempeño de la Regresión Logística.

La curva ROC del modelo de regresión logística (Figura 10) muestra un área bajo la curva (AUC) de 0.81, lo que evidencia una buena capacidad para discriminar entre clases positivas

y negativas. La curva se aleja significativamente de la diagonal aleatoria, indicando un desempeño superior al azar. La matriz de confusión (Figura 10) revela que el modelo clasifica correctamente 75 de los casos negativos y 81 de los casos positivos, mientras que incurre en 30 falsos positivos y 24 falsos negativos. Esto refleja un balance aceptable entre sensibilidad y especificidad, aunque con un margen de mejora en la reducción de falsos positivos para optimizar la precisión del modelo.




Figura 11. Coeficientes para las covariables de la Regresión Logística.

El gráfico de coeficientes de la regresión logística muestra el peso y la dirección de cada variable en la predicción del modelo. La variable EdadMa destaca como la de mayor influencia negativa, con un coeficiente cercano a -1, lo que indica que valores más altos de esta variable disminuyen la probabilidad de un evento positivo. Por el contrario, Moho_Z y Bario son las variables con mayor influencia positiva, seguidas por Bismuto y Cromo, lo que sugiere que un incremento en estas variables está asociado con una mayor probabilidad de ocurrencia del evento. El resto de las variables, como Mercurio y Azufre, tienen un impacto menor en la predicción, aunque su contribución sigue siendo positiva.

Metrica	BASE	SLX
AUC-ROC	0.81	0.87
Accuracy	0.74	0.80
Precisión	0.73	0.78
Recall	0.77	0.82
F1-score	0.75	0.80
Pseudo-R2McFadden	0.24	0.34
Moran's I	0.35	0.33
p-value (normalidad)	0	0
Variable	Coefficiente	
EdadMa	-1.00	1.00
Moho_Z	0.45	0.45
Bario	0.37	0.37
Bismuto	0.18	0.18
Cromo	0.17	0.17
Mercurio	0.03	0.03
Azufre	0.03	0.03
Moho_Z	-0.01	0.01
Antimonio	-0.01	0.01
Plata	0.00	0.00

Tabla 2. Comparación modelos Regresión Logística Base y Regresión Logística con SLX

La comparación entre los modelos de regresión logística base y SLX (Tabla 2) muestra una mejora clara en el rendimiento al incorporar efectos espaciales. El modelo SLX alcanza un AUC-ROC de 0.87, superior al 0.81 del modelo base, lo que indica una mayor capacidad para discriminar entre eventos positivos y negativos. Del mismo modo, la precisión y el recall aumentan de 0.73 y 0.77 en el modelo base a 0.78 y 0.82 en el SLX, reflejando una mejor identificación tanto de verdaderos positivos como de verdaderos negativos. El valor del pseudo R^2 de McFadden también se incrementa significativamente, pasando de 0.24 en el modelo base a 0.34 en el modelo SLX, lo que sugiere un mejor ajuste global. En cuanto a la autocorrelación espacial de los residuos, el Moran's I se reduce levemente (0.35 a 0.33), aunque el p-value sigue indicando significancia estadística, evidenciando la persistencia de cierta dependencia espacial. Respecto a los coeficientes, variables como Moho_Z y Bario mantienen un efecto positivo similar en ambos modelos, mientras que EdadMa cambia su

comportamiento, pasando de un impacto negativo en el modelo base a positivo en el SLX, lo que resalta cómo los efectos espaciales pueden alterar la interpretación de las variables.




Figura 12. Graficas de desempeño de la Regresión Logística vs Regresión Logística SLX y matriz de confusión.

La comparación de las curvas ROC entre los modelos base y SLX (Figura 12) evidencia una mejora significativa en la capacidad predictiva cuando se incorporan efectos espaciales. El modelo base obtiene un AUC de 0.810, mientras que el modelo SLX alcanza un valor superior de 0.872, lo que indica una mejor discriminación entre clases. Este desempeño se refleja también en la matriz de confusión del modelo SLX, que muestra 81 verdaderos negativos y 86 verdaderos positivos, con solo 24 falsos positivos y 19 falsos negativos. En conjunto, estos resultados indican que el modelo SLX no solo incrementa la sensibilidad y la precisión en la clasificación, sino que también reduce los errores de predicción en comparación con el modelo base.

Parámetro	Valor
AUC-ROC	0.81
Accuracy	0.73
Precisión	0.70
Recall	0.79

Parámetro	Valor
F1-score	0.74
Pseudo-R ² (McFadden)	0.23
Moran's I	0.42
p-value (normalidad)	0.00
EdadMa	-1.001
Bario	0.45
Moho_Z	0.41
Cromo	0.16
Bismuto	0.16
Moho_Z (var)	-0.11
Antimonio	-0.05
Mercurio	0.03
Azufre	-0.01
Plata	0.00

Tabla 3. Modelo SAR métricas de desempeño y coeficientes.

El modelo SAR presenta un rendimiento global comparable al modelo logístico base, con un AUC-ROC de 0.81, una precisión del 70% y un recall del 79%, resultando en un F1-score de 0.74 y una exactitud total (accuracy) del 73%. El pseudo R² de McFadden alcanza un valor de 0.23, reflejando una mejora moderada en la capacidad explicativa respecto al modelo nulo. El análisis espacial de los residuales mediante Moran's I arroja un valor de 0.42 con un p-value de 0.00, indicando la existencia de autocorrelación espacial significativa, lo que justifica la inclusión de términos espaciales en el modelo. Entre los coeficientes más relevantes se observa un efecto negativo notable de la variable EdadMa (-1.001), mientras que Bario (0.45) y Moho_Z (0.41) destacan como predictores positivos, junto con Cromo y Bismuto (ambos 0.16). Variables como Antimonio (-0.05) y Azufre (-0.01) muestran influencias negativas menores, mientras que Plata (0.00) no presenta un efecto sustancial.




Figura 13. Graficas de desempeño del modelo SAR-Logit y matriz de confusión.

La curva ROC alcanza un AUC de 0.815, lo que indica una buena capacidad de discriminación entre eventos positivos y negativos. La matriz de confusión revela que el modelo clasificó correctamente 70 de los casos negativos y 83 de los positivos, mientras que cometió 35 falsos positivos y 22 falsos negativos. Esto se traduce en un equilibrio aceptable entre sensibilidad y especificidad, con una tendencia a priorizar la identificación de los eventos positivos (Figura 13).

5. Discusión de resultados

Métrica	BASE (Logística)	SLX	SAR- Logit
AUC-ROC	0.81	0.87	0.81
Accuracy	0.74	0.80	0.73
Precisión	0.73	0.78	0.70
Recall	0.77	0.82	0.79
F1-score	0.75	0.80	0.74
Pseudo-R ² (McFadden)	0.24	0.34	0.23
Moran's I	0.35	0.33	0.42
p-value (normalidad)	0.00	0.00	0.00

Tabla 4. Comparación de métricas entre modelos.

La comparación de los modelos logísticos BASE, SLX y SAR-Logit (Tabla 4) evidencia diferencias significativas en su capacidad predictiva y en la manera en que cada uno captura las dependencias espaciales presentes en los datos. El análisis del AUC-ROC muestra que el modelo SLX alcanza el mejor desempeño (0.87), superando al modelo BASE (0.81) y al SAR-Logit (0.81). Este resultado indica que la incorporación explícita de rezagos espaciales en las variables predictoras (WX) mejora notablemente la capacidad del modelo para discriminar entre eventos positivos y negativos. La curva ROC del modelo SLX presenta una mayor inclinación hacia la esquina superior izquierda, lo que sugiere que logra un balance más efectivo entre la tasa de verdaderos positivos y la tasa de falsos positivos.

En términos de métricas de clasificación, el modelo SLX sobresale con una exactitud de 0.80, frente a 0.74 del BASE y 0.73 del SAR-Logit. Esta mejora se refleja también en la precisión (0.78) y el recall (0.82), lo que indica que el modelo no solo reduce la proporción de falsos positivos, sino que también logra identificar un mayor número de verdaderos positivos. Por el contrario, el SAR-Logit, aunque incorpora una estructura de dependencia espacial mediante un término autorregresivo, muestra una precisión menor (0.70) y una sensibilidad de 0.79, lo que sugiere que su estructura no logra capturar por completo la variabilidad de los datos. El F1-score, que combina precisión y recall en una métrica única, refuerza esta conclusión: SLX alcanza un valor de 0.80, mientras que BASE y SAR-Logit se mantienen en 0.75 y 0.74, respectivamente.

El ajuste global de los modelos, evaluado mediante el pseudo- R^2 de McFadden, resalta el mejor desempeño del modelo SLX (0.34), seguido por BASE (0.24) y SAR-Logit (0.23).

Este indicador sugiere que el SLX es el modelo con mayor poder explicativo sobre la variable objetivo, lo que puede atribuirse a la inclusión de efectos espaciales en las variables independientes. No obstante, el análisis de la autocorrelación espacial residual, medido por Moran's I, revela que los residuos del modelo SAR-Logit presentan la mayor autocorrelación (0.42), mientras que SLX (0.33) logra reducirla en comparación con BASE (0.35). Este hallazgo refuerza la importancia de abordar explícitamente la dependencia espacial en los datos para evitar patrones espaciales no explicados.

Finalmente, los p-values asociados a Moran's I son prácticamente nulos (0.00) en todos los modelos, lo que confirma la presencia de autocorrelación espacial significativa. Este resultado implica que los procesos subyacentes en los datos no son independientes en el espacio, por lo que los modelos tradicionales sin componentes espaciales, como el BASE, podrían subestimar o sobrestimar la influencia de ciertas variables. En conjunto, los resultados sugieren que el modelo SLX no solo mejora la capacidad predictiva, sino que también representa un compromiso más adecuado entre ajuste estadístico y manejo de la estructura espacial de los datos, superando tanto al modelo logístico convencional como al SAR-Logit.

El gráfico de dispersión de Moran (Figura 14) para los residuos del modelo SLX (Figura) muestra una pendiente positiva con un índice de Moran (I) de 0.335, lo que indica la presencia de autocorrelación espacial en los residuos. Este valor sugiere que los errores del modelo no se distribuyen de forma aleatoria, sino que presentan agrupamientos espaciales significativos.




Figura 14. Plot Índice de Moran para SLX

En el contexto de nuestro estudio, esta autocorrelación residual señala que, aunque el modelo SLX incorpora efectos espaciales mediante el rezago de las covariables, todavía existen patrones espaciales en los datos que no han sido completamente capturados. Esto podría deberse a la influencia de variables no incluidas en el modelo o a interacciones espaciales más complejas que no se reflejan únicamente a través de los rezagos de las X.

En términos de interpretación geológica, la presencia de autocorrelación en los residuos puede reflejar que las zonas con alta probabilidad de ocurrencia de depósitos minerales comparten características espaciales o geoquímicas comunes que el modelo no logra explicar del todo, lo que refuerza la necesidad de explorar modelos espaciales más avanzados o de incorporar nuevas covariables.




Figura 15. Comparación de los mapas de predicción para los modelos implementados. De arriba a abajo: SAR, SLX y Reg. Log.




Figura 16. Mapa de predicción del modelo SLX

El mapa de predicción generado con el modelo SLX (Figura 16) permite identificar patrones espaciales que reflejan áreas con alta probabilidad de ocurrencia de depósitos ígneo-metamórficos en la región de Antioquia y Caldas. Las zonas con tonalidades amarillas y verdes más intensas (valores de probabilidad superiores al 0.7) se concentran principalmente en el suroccidente de Antioquia, a lo largo del corredor montañoso que acompaña la cuenca

del río Cauca. Municipios como Andes, Betania y Jardín destacan como áreas prioritarias, debido a la combinación de factores geoquímicos y geofísicos que el modelo asocia con un mayor potencial mineral. Estas áreas corresponden a regiones históricamente vinculadas con la presencia de mineralizaciones auríferas y cuerpos ígneos intrusivos, lo que valida la coherencia geológica del resultado.

Otro núcleo importante de alta probabilidad se localiza en el occidente de Antioquia, particularmente en municipios como Urrao y Frontino, donde los valores predichos oscilan entre 0.6 y 0.8. Estas zonas coinciden con unidades de rocas metamórficas y complejos intrusivos, que han sido señalados en estudios previos como áreas con alto potencial para depósitos polimetálicos. La continuidad de estos valores en el paisaje montañoso sugiere que las características geoquímicas analizadas (como la concentración de bario, bismuto y cromo) son consistentes con el contexto geológico regional.

En el suroccidente de Caldas, el modelo identifica una franja de alta probabilidad en municipios como Supía, Marmato y Riosucio, con valores entre 0.7 y 0.9. Estas áreas son ampliamente reconocidas por su tradición minera y por la presencia de rocas filíticas y anfibolíticas mineralizadas, lo que refuerza la robustez del modelo. Además, se observa un núcleo de probabilidad moderada (0.5–0.7) en municipios como Manzanares y La Merced, lo cual podría indicar condiciones geológicas favorables que aún no han sido explotadas de forma intensiva.

Por otro lado, regiones como el nordeste de Antioquia, en la zona de Bajo Cauca (municipios de Nechí y Zaragoza), y el oriente de Caldas (municipios como Pensilvania y Victoria) presentan valores de probabilidad inferiores a 0.3. Esto sugiere que estas áreas no comparten los mismos rasgos geoquímicos y geofísicos asociados con la mineralización ígneo-metamórfica en comparación con el corredor montañoso occidental. Este contraste destaca

la importancia de focalizar las campañas de exploración en las zonas de alta probabilidad identificadas, optimizando recursos y aumentando las posibilidades de éxito en la prospección minera.

6. Conclusiones

1. La incorporación de componentes espaciales mejora el poder predictivo: El modelo SLX, al integrar rezagos espaciales de las covariables, mostró un desempeño superior al modelo logístico base y al SAR-Logit, alcanzando valores de AUC-ROC de 0.87, F1-score de 0.80 y un pseudo- R^2 de McFadden de 0.34. Esto demuestra que el uso de información espacial adicional permite capturar mejor la distribución de las mineralizaciones y proporciona mapas de susceptibilidad más precisos.

2. Persistencia de la autocorrelación espacial en los residuos: Aunque el SLX reduce ligeramente el índice de Moran respecto al modelo base (0.33 frente a 0.35), la presencia de autocorrelación espacial residual evidencia que existen patrones espaciales no completamente explicados. Esto sugiere que se requiere explorar modelos más complejos o incluir nuevas variables geológicas, estructurales o geomorfológicas para mejorar el ajuste.

3. Importancia de las variables geológicas y geoquímicas clave: Los coeficientes estimados destacan variables como EdadMa, Moho_Z y Bario como los predictores más influyentes en la probabilidad de ocurrencia de depósitos. La relación positiva de Moho_Z y Bario con las mineralizaciones refuerza su rol como indicadores geoquímicos y estructurales en contextos ígneo-metamórficos, mientras que EdadMa ofrece una diferenciación temporal relevante en los procesos mineralizantes.

4. Identificación de zonas prioritarias para la exploración: El análisis espacial reveló áreas de alta probabilidad de mineralización en el suroccidente de Antioquia (municipios de Andes, Betania y Jardín) y en el suroccidente de Caldas (Supía, Marmato y Riosucio), todas con

valores de probabilidad superiores a 0.7. Estos resultados permiten orientar futuras campañas de prospección minera hacia regiones con mayor potencial, optimizando recursos y esfuerzos.

5. Potencial de integración metodológica en exploración minera: La combinación de regresión logística, modelos espaciales (SLX y SAR-Logit) y técnicas de interpolación como IDW se evidencia como una estrategia robusta para la evaluación de prospectividad minera. La metodología no solo predice la distribución de depósitos, sino que también ofrece un marco analítico adaptable a otras regiones con características geológicas similares.

Agradecimientos

Agradezco al buen desarrollo de la materia y al docente que la imparte. AL SGC por disponer de los datos y a la Facultad de Minas de la universidad Nacional de Colombia por ser una fuente de conocimiento y formación integra.

Referencias

- Anselin, L. (1995). Local Indicators of Spatial Association—LISA. *Geographical Analysis*, 27(2), 93–115.
- Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer.
- Coro Chasco, M. (2013). *Econometría espacial aplicada*. Madrid: Ed. Asociación Española de Ciencia Regional.
- Fotheringham, A. S., Brunsdon, C., & Charlton, M. (2002). *Geographically Weighted Regression: the analysis of spatially varying relationships*. Wiley.
- Gómez Tapias, J., Montes Ramírez, N. E., Alcarcel Gutiérrez, F. A., & Ceballos Hernández, J. A. (2015). *Catálogo de dataciones radiométricas de Colombia en ArcGIS y Google Earth*. En J. Gómez & M. F. Almanza (Eds.), **Compilando la geología de Colombia: Una visión a 2015** (Publicaciones Geológicas Especiales 33, pp. 63–79). Servicio Geológico Colombiano, Bogotá.
- Getis, A., & Ord, J. K. (1992). The Analysis of Spatial Association by Use of Distance Statistics. *Geographical Analysis*, 24(3), 189–206.
- LeSage, J. P., & Pace, R. K. (2009). *Introduction to Spatial Econometrics*. CRC Press.

- Servicio Geológico Colombiano. Atlas Geoquímico de Colombia, versión 2022 [Mapa geoquímico multipropósito]. Bogotá: Servicio Geológico Colombiano; 2022.
- Moran, P. (1950). Notes on continuous stochastic phenomena. *Biometrika*, 37(1/2), 17–23.
- Servicio Geológico Colombiano, 2020. Depósitos Generalizados 2020 , Mapa Metalogénico de Colombia versión 2020., Bogotá: SGC, <https://www.sgc.gov.co/>.
- Tobler, W. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(sup1), 234–240.